



PROPOSAL TUGAS AKHIR - TD123456

**DETEKSI GESTURE UNTUK IMPLEMENTASI
TOUCHLESS INTERFACE DI VENDING MACHINE
PUBLIK DENGAN MENGGUNAKAN LSTM DAN
MEDIAPIPE**

Michael

NRP 5024231022

Dosen Pembimbing

Dr. Eko Mulyanto Yuniarno, S.T., M.T.

NIP 1 9680601 199512 1 009

Dr. Diah Puspito Wulandari, S.T., M.Sc.

NIP 1 9801219 200501 2 001

Program Studi Strata 1 (S1) Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

[Halaman ini sengaja dikosongkan]

LEMBAR PENGESAHAN

DETEKSI GESTURE UNTUK IMPLEMENTASI *TOUCHLESS INTERFACE* DI *VENDING MACHINE* PUBLIK DENGAN MENGGUNAKAN LSTM DAN MEDIAPIPE

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat memperoleh gelar Sarjana Teknik pada Program Studi S-1

Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Oleh: **Michael**

NRP. 5024231022

Disetujui Oleh:

Dr. Eko Mulyanto Yuniarno, S.T., M.T.

NIP: 1 9680601 199512 1 009 (Pembimbing)

Dr. Diah Puspito Wulandari, S.T., M.Sc.

NIP: 1 9801219 200501 2 001 (Ko-Pembimbing)

Mengetahui,

Kepala Departemen Teknik Komputer FTEIC-ITS

Dr. Arief Kurniawan, S.T., M.T.

NIP 19740907200212 1 001

SURABAYA

April, 2026

[Halaman ini sengaja dikosongkan]

ABSTRAK

DETEKSI GESTURE UNTUK IMPLEMENTASI *TOUCHLESS* INTERFACE DI *VENDING MACHINE* PUBLIK DENGAN MENGGUNAKAN LSTM DAN MEDIAPIPE

Nama Mahasiswa / NRP: Michael / 5024231022

Departemen : Teknik Komputer FTEIC - ITS

Dosen Pembimbing : Dr. Eko Mulyanto Yuniarno, S.T., M.T.

Abstrak

Mesin penjual otomatis (*vending machine*) merupakan infrastruktur krusial di ruang publik yang efisien, namun interaksi fisik melalui layar sentuh menimbulkan risiko transmisi virus dan masalah higienitas permukaan secara signifikan akibat fenomena *coupled hand and surface hygiene*. Antarmuka tanpa sentuhan (*touchless interface*) muncul sebagai solusi preventif yang krusial untuk memutus rantai transmisi mikrobial. Meskipun kerangka kerja *computer vision* seperti MediaPipe dan arsitektur *Long Short-Term Memory* (LSTM) telah terbukti ampuh dalam pengenalan gestur tangan dinamis, implementasinya mayoritas masih terbatas pada lingkungan laboratorium yang terkontrol atau perangkat seluler. Terdapat celah penelitian terkait penerapan dan optimasi sistem secara *real-time* pada perangkat *edge computing* di lingkungan publik yang dinamis, khususnya untuk mengatasi tantangan fluktuasi pencahayaan dan latar belakang yang kompleks. Penelitian ini bertujuan untuk mengimplementasikan dan mengoptimalkan sistem *touchless interface* berbasis pengenalan gestur tangan dinamis menggunakan kerangka kerja MediaPipe dan arsitektur LSTM pada *vending machine* publik. Metode eksperimental digunakan untuk merancang dan mengevaluasi sistem yang diproses sepenuhnya secara lokal menggunakan *Single Board Computer* Raspberry Pi 5. Tahapan penelitian mencakup pengumpulan *dataset* gestur navigasi dasar, ekstraksi fitur *landmark* 3D menggunakan MediaPipe, pelatihan model LSTM, optimasi ukuran model menjadi TensorFlow Lite, hingga eksekusi inferensi *real-time* untuk mengontrol aktuator ESP32-S3 serta evaluasi akhir pada kinerja akhir system secara kuantitatif.

Kata kunci: *Vending Machine*, Antarmuka Tanpa Sentuhan, Pengenalan Gestur Tangan Dinamis, *Long Short-Term Memory* (LSTM), MediaPipe, Raspberry Pi 5.

[Halaman ini sengaja dikosongkan]

ABSTRACT

GESTURE DETECTION FOR IMPLEMENTATION OF TOUCHLESS INTERFACE IN PUBLIC VENDING MACHINES USING LSTM AND MEDIAPIPE

Student Name / NRP: Michael / 5024231022

Department : Teknik Komputer FTEIC - ITS

Advisor : Dr. Eko Mulyanto Yuniarno, S.T., M.T.

Abstract

Vending machines are crucial and efficient public space infrastructures; however, physical interaction via touchscreens poses significant risks of viral transmission and surface hygiene issues due to the coupled hand and surface hygiene phenomenon. Touchless interfaces have emerged as a critical preventive solution to break the chain of microbial transmission. Although computer vision frameworks such as MediaPipe and Long Short-Term Memory (LSTM) architectures have proven reliable for dynamic hand gesture recognition, their implementations are predominantly limited to controlled laboratory environments or mobile devices. There is a research gap regarding the real-time deployment and optimization of these systems on edge computing devices in dynamic public environments, specifically in addressing challenges like lighting fluctuations and complex backgrounds. This research aims to implement and optimize a touchless interface system based on dynamic hand gesture recognition using the MediaPipe framework and LSTM architecture for public vending machines. An experimental method is utilized to design and evaluate the system, which is processed entirely locally using a Raspberry Pi 5 Single Board Computer. The research stages encompass basic navigational gesture dataset collection, 3D landmark feature extraction using MediaPipe, LSTM model training, model size optimization into TensorFlow Lite, and real-time inference execution to control an ESP32-S3 actuator along with evaluation on the final system's performance quantitatively.

Keywords: Vending Machine, Touchless Interface, Dynamic Hand Gesture Recognition, Long Short-Term Memory (LSTM), MediaPipe, Raspberry Pi 5.

[Halaman ini sengaja dikosongkan]

DAFTAR ISI

ABSTRAK	v
DAFTAR ISI	ix
DAFTAR GAMBAR	xi
DAFTAR TABEL	xiii
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah atau Ruang Lingkup	2
1.4 Tujuan	3
1.5 Manfaat	3
2 TINJAUAN PUSTAKA	5
2.1 Hasil Penelitian Terdahulu	5
2.1.1 MM-Wave Radar-Based Recognition of Multiple Hand Gestures Using Long Short-Term Memory (LSTM) Neural Network	5
2.1.2 MediaPipe's Landmarks with RNN for Dynamic Sign Language Recognition	5
2.1.3 TensorFlow, Computer Vision, and Edge AI-based Face Recognition Atten- dance Monitoring System Using Raspberry Pi 5	6
2.2 Teori/Konsep Dasar	6
2.2.1 Vending Machine	6
2.2.2 Hand Gesture Recognition	7
2.2.3 MediaPipe	7
2.2.4 Recurrent Neural Network (RNN)	7
2.2.5 Long Short-Term Memory (LSTM)	8
2.2.6 Tensorflow dan Tensorflow Lite	9

2.2.7	Raspberry Pi 5	9
3	METODOLOGI	11
3.1	Metode yang Digunakan	11
3.2	Bahan dan Peralatan yang Digunakan	11
3.2.1	Hardware	11
3.2.2	Software	11
3.3	Urutan Pelaksanaan Penelitian	12
3.3.1	Pengambilan Dataset	12
3.3.2	Ekstraksi Fitur & Preprocessing	12
3.3.3	Pelatihan & Pengembangan LSTM	12
3.3.4	Pengujian & Optimisasi LSTM	12
3.3.5	Instalasi OS Raspberry Pi 5	13
3.3.6	Integrasi Model & OS di Raspberry Pi 5	13
3.3.7	Inferensi Real-Time & Kontrol Aktuator	13
3.3.8	Evaluasi	13
3.3.9	Jadwal Pelaksanaan Penelitian	13
4	HASIL SEMENTARA	15
4.1	Software	15
4.1.1	Akuisisi Dataset dan Pelatihan	15
4.1.2	Uji Coba Model dan <i>Debugging</i>	15
4.2	Hardware	15
4.2.1	Setup Raspberry Pi dan Web Cam	15
4.2.2	Uji Coba Rangkaian	16
4.3	Kesimpulan Sementara	16
	DAFTAR PUSTAKA	19

DAFTAR GAMBAR

2.1	Vending Machine	6
2.2	Landmark Tangan oleh MediaPipe	7
2.3	Raspberry Pi 5	10
3.1	Diagram Blok Alur Penelitian	12
4.1	Proses akuisisi dataset dan pelatihan model	15
4.2	Uji coba model - Kelas Unknown	15
4.3	Uji coba model - Kelas OK	15
4.4	Setup Raspberry Pi dan Web Cam	16
4.5	Uji coba rangkaian sebelum menggunakan komponen fisik	16

[Halaman ini sengaja dikosongkan]

DAFTAR TABEL

3.1	Tabel timeline	13
-----	--------------------------	----

[Halaman ini sengaja dikosongkan]

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Mesin penjual otomatis (vending machine) telah menjadi salah satu infrastruktur krusial di ruang publik modern, termasuk di lingkungan kampus. Mesin ini menawarkan efisiensi transaksi tanpa operator dan merupakan solusi utama saat mahasiswa tidak memiliki cukup waktu atau akses ke kantin untuk mendapatkan makanan [1]. Selain itu, mesin ini juga memiliki potensi luas dalam meningkatkan kualitas layanannya dengan integrasi teknologi Internet of Things (IoT) dan algoritma Support Vector Machine (SVM). Kedua teknologi tersebut kini menjadi sangat umum diterapkan untuk menciptakan mesin cerdas yang mampu memberikan rekomendasi produk yang terpersonalisasi serta manajemen stok yang lebih akurat secara real-time sehingga mampu meningkatkan penjualan [2].

Namun, interaksi fisik melalui layar sentuh pada mesin-mesin ini menciptakan permasalahan berupa risiko kesehatan yang signifikan. Penelitian menunjukkan bahwa permukaan publik di lingkungan dengan mobilitas serta interaksi tinggi berfungsi sebagai "hubs" utama penyebaran virus, di mana frekuensi kontak tangan manusia terhadap benda mati berbanding lurus dengan Virus Transmission Ability (VTA) atau kemampuan transmisi virus di area tersebut [3]. Masalah ini diperparah oleh fenomena coupled hand and surface hygiene, di mana pembersihan permukaan secara acak sering kali tidak efektif karena siklus re-kontaminasi yang cepat antara tangan manusia dan benda mati [4]. Hal ini semakin difokuskan pasca pandemi COVID-19 yang menekankan pentingnya antarmuka tanpa sentuhan (contactless) sebagai langkah preventif dalam mengurangi penyebaran virus melalui kontak fisik [5].

Merespons permasalahan tersebut, kesadaran akan layanan tanpa sentuh (contactless services) meningkat pesat. Salah satu contoh penelitian antarmuka tanpa sentuh yang relevan adalah pengembangan interaksi virtual sebagai pengganti interaksi dengan perangkat fisik, seperti mouse atau layar sentuh [6]. Dalam perkembangannya, ekstraksi titik koordinat tangan (landmarks) untuk mendukung interaksi tersebut juga telah dieksplorasi menggunakan MediaPipe yang terbukti akurat meskipun terdapat gangguan visual pada latar belakang [7]. Sementara itu, untuk mencapai pengenalan gestur secara real-time dan berkelanjutan dengan tingkat akurasi yang stabil, beberapa penelitian terkini mulai memanfaatkan arsitektur Long Short-Term Memory (LSTM) [8]. Selain LSTM, penelitian terbaru juga menunjukkan bahwa model GRU dapat menjadi alternatif yang lebih ringan dan cepat untuk prediksi pada perangkat dengan sumber daya terbatas tanpa mengorbankan akurasi signifikan [9].

Meskipun sistem berbasis MediaPipe telah dikembangkan secara luas, fokus penelitian sejauh ini masih didominasi oleh implementasi pada pengenalan bahasa isyarat dan kendali pada robot bedah [5], [9]–[12]. Mayoritas dari aplikasi tersebut umumnya baru diuji coba dalam lingkungan laboratorium yang terkontrol atau perangkat ponsel pintar sehingga sejauh ini, implementasinya pada vending machine di ruang publik masih sangat terbatas [5], [11]. Hal ini menyisakan celah penelitian terkait aspek praktikal seperti latensi akibat fluktuasi jaringan, kendala pencahayaan di lingkungan yang dinamis, serta ketergantungan pada curated dataset yang kurang merepresentasikan kondisi riil di lapangan [5], [9], [11], [12]. Masih sedikit penelitian yang secara mendalam menguji ketahanan sistem terhadap latar belakang yang kompleks

dan kasus dengan kondisi berupa banyak pengguna sekaligus (multi-user).

Berdasarkan permasalahan tersebut, diperlukan sebuah sistem interaksi yang responsif, adaptif terhadap kondisi lingkungan publik yang dinamis, dan higienis untuk memutus rantai transmisi mikrobial. Oleh karena itu, penelitian ini diusulkan dengan tujuan untuk mengimplementasikan Touchless Interface pada vending machine publik dengan mengintegrasikan kerangka kerja MediaPipe dan arsitektur LSTM (Long Short-Term Memory). Penelitian ini difokuskan pada optimasi performa agar model dapat menangani dinamika temporal dari gerakan tangan secara berkelanjutan dan agar dapat dijalankan pada perangkat keras secara real-time pada unit vending machine di lingkungan publik.

1.2 Rumusan Masalah

Berdasarkan identifikasi pada latar belakang, maka rumusan masalah dalam penelitian ini adalah:

- a. Bagaimana cara merancang dan mengimplementasikan sistem *touchless interface* berbasis pengenalan gestur tangan menggunakan kerangka kerja MediaPipe dan arsitektur LSTM pada unit *vending machine* publik?
- b. Bagaimana cara mengoptimalkan performa model klasifikasi gestur agar mampu berjalan secara *real-time* dengan latensi yang rendah dan tingkat akurasi yang tinggi saat dihadapkan pada kondisi lingkungan publik yang dinamis (seperti fluktuasi pencahayaan, *background* yang kompleks, dan sebagainya)?

1.3 Batasan Masalah atau Ruang Lingkup

Untuk menjaga agar penelitian ini tetap fokus dan terarah, ditetapkan beberapa batasan masalah sebagai berikut:

- a. **Algoritma dan Kerangka Kerja:** Deteksi *landmark* tangan menggunakan MediaPipe, sedangkan pemrosesan sekuensial dan klasifikasi gestur menggunakan arsitektur LSTM. Parameter dan hiperparameter pada model akan disesuaikan untuk mencapai keseimbangan antara akurasi dan kecepatan inferensi.
- b. **Kondisi Lingkungan dan Pengujian:** Pengujian sistem akan dilakukan pada lingkungan yang mensimulasikan ruang publik/kampus, dengan variasi tingkat pencahayaan (terang dan redup) serta latar belakang visual yang heterogen, tetapi tidak berfokus pada pengujian performa saat terjadi *extreme occlusion* (kasus di mana terjadi halangan total pada objek tangan).
- c. **Jenis Gestur:** Variabel gestur tangan yang dilatih dan dideteksi dibatasi pada serangkaian gerakan intuitif dasar yang diperlukan untuk mengoperasikan *vending machine*, seperti navigasi layar (atas, bawah, kiri, kanan) dan konfirmasi pemilihan produk.
- d. **Parameter yang Diabaikan:** Penelitian ini berfokus sepenuhnya pada aspek perancangan antarmuka pengguna (*User Interface/User Experience*) berbasis *computer vision*. Aspek keamanan transaksi finansial, *payment gateway*, dan perancangan mekanik internal dari *vending machine* diasumsikan sudah berjalan dengan baik dan berada di luar ruang lingkup penelitian ini.

1.4 Tujuan

Penelitian Tugas Akhir ini bertujuan untuk mengatasi permasalahan yang telah dirumuskan. Tujuan tersebut adalah sebagai berikut:

- a. Mengimplementasikan *touchless interface* yang fungsional pada *vending machine* publik dengan mengintegrasikan kerangka kerja MediaPipe untuk ekstraksi fitur spasial dan arsitektur LSTM untuk menangani dinamika temporal dari gerakan tangan secara berkelanjutan.
- b. Menghasilkan sistem pengenalan gestur dengan latensi rendah dan akurasi tinggi yang mampu dijalankan pada perangkat keras secara *real-time*, sehingga mampu beradaptasi dengan kondisi lingkungan publik yang dinamis demi memberikan pengalaman pengguna yang optimal.

1.5 Manfaat

Hasil dari penelitian ini diharapkan dapat memberikan manfaat baik secara teoritis maupun praktis:

- a. **Manfaat Teoritis:** Memperkaya literatur dan kajian akademis di bidang *Computer Vision* dan *Artificial Intelligence*, khususnya terkait optimasi penggunaan model MediaPipe dan LSTM pada studi kasus lingkungan *real-world* dan perangkat keras *edge* dengan komputasi terbatas, bukan sekadar di dalam lingkungan laboratorium.
- b. **Manfaat Praktis:** Menghasilkan purwarupa atau sistem interaksi alternatif pada *vending machine* yang 100% tanpa sentuhan. Hal ini secara langsung dapat diterapkan di ruang publik atau fasilitas kampus untuk membantu mengurangi siklus re-kontaminasi permukaan benda mati, menjaga higienitas, dan memberikan rasa aman bagi pengguna.

[Halaman ini sengaja dikosongkan]

BAB 2 TINJAUAN PUSTAKA

2.1 Hasil Penelitian Terdahulu

Pada bagian ini, akan dibahas hasil penelitian terdahulu yang relevan dengan penelitian yang akan dilakukan. Penelitian terdahulu tersebut akan dibahas berdasarkan metode yang digunakan, hasil yang diperoleh, dan kesimpulan yang diambil.

2.1.1 MM-Wave Radar-Based Recognition of Multiple Hand Gestures Using Long Short-Term Memory (LSTM) Neural Network

Penelitian relevan yang menjadi referensi penelitian ini dilakukan oleh Grobelny, P., dan Narbudowicz, A. (2022) dengan judul “*MM-Wave Radar-Based Recognition of Multiple Hand Gestures Using Long Short-Term Memory (LSTM) Neural Network*” [5]. Aplikasi dari penelitian ini adalah untuk menciptakan antarmuka pengguna tanpa sentuhan (*contactless user interface*) yang dapat diimplementasikan pada mesin penjual otomatis (*vending machine*), ATM, dan perangkat sejenisnya.

Metode yang digunakan adalah mengklasifikasikan hingga 12 jenis gestur tangan menggunakan model jaringan *Long Short-Term Memory* (LSTM) dan membandingkannya dengan arsitektur lain, yaitu GRU dan RNN. Input model berasal dari data ekstraksi radar *Frequency-Modulated Continuous-Wave* (FMCW) berupa posisi koordinat X, posisi Y, dan kecepatan *Doppler*, di mana parameter-parameter ini kemudian disusun langsung dalam bentuk matriks sekuensial tanpa harus diubah menjadi format gambar spektrogram. Output dari jaringan saraf ini kemudian memprediksi probabilitas tertinggi untuk menentukan kelas dari gestur tersebut.

Hasil dari penelitian ini menunjukkan bahwa pendekatan yang diusulkan memiliki performa yang sangat baik, di mana arsitektur LSTM terbaik mampu mencapai tingkat akurasi sebesar 94.4% untuk pengenalan 12 gestur, dan meningkat menjadi 97.3% saat dibatasi pada 10 gestur. Selain itu, sistem menunjukkan ketahanan yang stabil dengan penurunan akurasi maksimal hanya sekitar 2.24% ketika diuji pada pengguna baru yang belum pernah masuk di dalam data pelatihan.

2.1.2 MediaPipe’s Landmarks with RNN for Dynamic Sign Language Recognition

Penelitian relevan lain yang menjadi referensi penelitian ini dilakukan oleh Samaan, G.H., dkk. (2022) dengan judul “*MediaPipe’s Landmarks with RNN for Dynamic Sign Language Recognition*” [9]. Aplikasi akhir dari penelitian ini adalah sistem pengenalan bahasa isyarat dinamis (*Dynamic Sign Language*) untuk menjembatani kesenjangan komunikasi antara komunitas tunarungu dan masyarakat umum.

Metode yang digunakan adalah mengklasifikasikan 10 jenis kosakata bahasa isyarat sehari-hari dengan membandingkan tiga arsitektur model *Recurrent Neural Network* (RNN) yang berbeda, yaitu GRU, LSTM, dan Bi-LSTM. Input model berasal dari proses ekstraksi fitur menggunakan *framework* MediaPipe yang melacak letak dan bentuk dengan menghasilkan *keypoints* (titik referensi) pada tangan, postur tubuh (*pose*), dan wajah dalam ruang koordinat spasial 3D dari sekumpulan urutan *frame* video. Parameter-parameter sekuensial ini kemudian secara langsung dimasukkan ke dalam model jaringan untuk diproses. Output dari jaringan saraf ini kemudian memprediksi probabilitas tertinggi untuk menentukan label atau makna kosakata dari gerakan isyarat dinamis tersebut.

Hasil dari penelitian ini menunjukkan bahwa pendekatan yang diusulkan memiliki performa yang sangat baik, di mana ketiga arsitektur mampu mencapai tingkat akurasi pengujian lebih dari 99%. Secara spesifik, model GRU terbukti menjadi arsitektur yang paling optimal

dengan tingkat akurasi mencapai 100% pada data pengujian, baik saat menggunakan fitur *key-points* wajah maupun tidak. Selain itu, sistem menunjukkan bahwa pendekatan GRU jauh lebih efisien karena memiliki parameter yang lebih sedikit, komputasi yang lebih ringan, serta waktu prediksi yang lebih cepat untuk data sekuensial yang kompleksitasnya rendah, menjadikannya pilihan yang sempurna untuk diimplementasikan secara langsung pada *smartphone* atau perangkat *mobile*.


2.1.3 TensorFlow, Computer Vision, and Edge AI-based Face Recognition Attendance Monitoring System Using Raspberry Pi 5

Penelitian relevan lain yang menjadi referensi penelitian ini dilakukan oleh Ranjan, P., dkk. (2025) dengan judul “*TensorFlow, Computer Vision, and Edge AI-based Face Recognition Attendance Monitoring System Using Raspberry Pi 5*” [22]. Aplikasi akhir dari penelitian ini adalah untuk menciptakan sistem pemantauan kehadiran otomatis di lingkungan pendidikan dengan tujuan untuk menjaga privasi, menghemat biaya, serta mencegah kontak fisik (*non-obtrusive*). Metode yang digunakan adalah memproses deteksi dan pengenalan wajah sepenuhnya secara lokal pada perangkat *edge* (Raspberry Pi 5) yang dioptimalkan dengan *framework* TensorFlow Lite. Input model berasal dari tangkapan kamera USB 720p berupa *frame* video *real-time*, yang kemudian diekstraksi *embedding* wajahnya menggunakan arsitektur model *deep learning* seperti MobileNetV2, EfficientNet-Lite, atau ResNet-18 yang telah melalui proses kuantisasi INT8. Output dari sistem ini adalah hasil validasi kecocokan wajah menggunakan rumus perhitungan *cosine similarity* dengan data yang sudah terdaftar, yang selanjutnya dicatat ke dalam database SQLite lokal terenkripsi dan ditampilkan pada *dashboard* layar TFT. Hasil dari penelitian ini menunjukkan bahwa sistem mampu mencapai tingkat akurasi pengenalan yang tinggi di berbagai tantangan kondisi, seperti pencahayaan redup dan wajah yang terhalang (oklusi) oleh masker maupun kacamata. Dengan mengimplementasikan model MobileNetV2, sistem ini mampu beroperasi secara efisien dengan waktu inferensi 0,32 hingga 0,40 detik per *frame* (2,5–3 FPS) tanpa memerlukan pemrosesan komputasi awan (*cloud*), sehingga sangat meminimalkan latensi dan menjaga keamanan data biometrik pengguna.

2.2 Teori/Konsep Dasar

2.2.1 Vending Machine

Mesin Penjual Otomatis (*Vending Machine*) adalah perangkat otomatis yang mampu mengeluarkan makanan dan minuman tanpa campur tangan manusia. Perkembangan teknologi pada *vending machine* telah mempengaruhi perilaku konsumen serta tren pasar ritel otomatis secara signifikan, di mana integrasi fitur-fitur cerdas kini menjadi standar dalam meningkatkan pengalaman pengguna [15]. Untuk menghadapi dinamika pasar tersebut, konstruksi dan optimasi dengan mengintegrasikan algoritma kecerdasan buatan (*Artificial Intelligence*) pada *vending machine* kini sudah mulai dilakukan [16].



Gambar 2.1: Vending Machine

2.2.2 Hand Gesture Recognition

Pengenalan Gestur Tangan (*Hand Gesture Recognition*) adalah teknologi yang memungkinkan sistem komputer atau mesin untuk menerjemahkan gerakan tangan manusia sebagai perintah atau input [13]. Teknologi ini merupakan komponen krusial dalam mewujudkan Interaksi Manusia-Mesin (*Human-Machine Interaction/HMI*) dan Interaksi Manusia-Komputer (*Human-Computer Interaction/HCI*) yang hasilnya natural dan akurat tanpa memerlukan kontak fisik [10].

Dalam *Hand Gesture Recognition*, gestur tangan dapat diklasifikasikan menjadi dua kategori utama, yaitu gestur statis dan gestur dinamis [10]. **Gestur statis** mengacu pada postur atau orientasi jari tangan yang diam pada satu waktu tertentu, sedangkan **gestur dinamis** melibatkan serangkaian pergerakan lintasan tangan dan jari yang dapat berubah seiring berjalannya waktu sehingga membutuhkan analisis data sekuensial.


Pada penelitian ini, *Hand Gesture Recognition* akan berfokus pada pengenalan gestur dinamis. Ini karena gestur dinamis mampu menyampaikan perintah kompleks dengan pengalaman yang lebih natural bagi penggunanya.

2.2.3 MediaPipe

MediaPipe adalah sebuah kerangka kerja (*framework*) *machine learning* sumber terbuka yang dikembangkan oleh Google. *Framework* ini dirancang untuk membangun saluran pemrosesan data multimodal lintas platform [9]. Dalam konteks pengenalan gestur tangan berbasis *computer vision*, salah satu solusi utama yang ditawarkan oleh *framework* ini adalah MediaPipe Hand Landmarker. Solusi ini berfungsi untuk mendeteksi dan melacak keberadaan tangan manusia di dalam sebuah gambar maupun *frame* video secara *real-time* [17].

Secara teknis, MediaPipe menggunakan model *machine learning* yang telah dilatih secara ekstensif untuk memprediksi 21 titik koordinat 3D (*landmarks*) pada struktur tangan manusia. Keluaran dari model ini terdiri dari tiga sumbu koordinat di bidang spasial, yaitu x, y, dan z. Nilai koordinat x dan y dinormalisasi ke dalam rentang [0.0, 1.0] yang dipetakan masing-masing terhadap lebar dan tinggi piksel gambar. Sementara itu, koordinat z merepresentasikan kedalaman titik tersebut dari kamera proyektif, di mana titik pangkal pergelangan tangan (*wrist*) digunakan sebagai titik referensi kedalaman. Selain ekstraksi koordinat, sistem ini juga menyediakan nilai probabilitas *handedness* untuk mengklasifikasikan apakah tangan yang terdeteksi adalah tangan kanan atau kiri [17].

Pada penelitian ini, MediaPipe memegang peran penting dalam mengekstraksi fitur tangan secara *real-time*. Pengambilan fitur tangan secara sekuensial ini nantinya akan menjadi fondasi dasar dari model LSTM untuk mengenali pola gestur tangan dinamis.



Gambar 2.2: Landmark Tangan oleh MediaPipe

2.2.4 Recurrent Neural Network (RNN)

Recurrent Neural Network (RNN) adalah jenis jaringan saraf yang memiliki kemampuan untuk memproses, mengekstraksi fitur, dan mempelajari data yang bersifat sekuensial [18].

Berbeda dengan jaringan saraf tradisional yang selalu mengasumsikan bahwa setiap input berdiri sendiri dan bersifat independen, RNN memiliki struktur dengan koneksi yang berulang [18]. Struktur ini memungkinkan informasi dari proses sebelumnya tetap dipertahankan dan diteruskan di dalam jaringan, sehingga informasi sebelumnya dapat mempengaruhi output dari proses [18].

Secara teknis, RNN memproses urutan data dengan mengambil output yang dihasilkan dari sebuah node pada langkah sebelumnya, lalu menggunakannya kembali sebagai input untuk node pada langkah saat ini [18]. Mekanisme umpan balik ini memungkinkan jaringan untuk mempertahankan memori historis dari data sebelumnya, sehingga menjadikannya sangat efektif untuk mengenali pola pada urutan data yang berkelanjutan [18].

Meskipun cukup *robust* untuk data sekuensial jangka pendek, RNN memiliki kelemahan matematis mendasar ketika dihadapkan pada urutan data yang terlalu panjang, yaitu rentan terhadap masalah gradien menghilang (*vanishing gradient problem*) [18]. Selama proses pelatihan mundur (*backpropagation*), nilai gradien yang dihitung dapat menyusut menjadi sangat kecil sehingga jaringan gagal memperbarui nilai bobotnya. Ini menyebabkan RNN kehilangan kemampuannya untuk mengaitkan informasi dari masa lalu yang jauh atau mempelajari ketergantungan jarak jauh (*long-term dependencies*) [18].

Keterbatasan dalam mempertahankan memori jangka panjang ini menjadi alasan kenapa penelitian ini memilih untuk menggunakan varian lain dari RNN, yaitu arsitektur *Long Short-Term Memory* (LSTM).

2.2.5 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan sebuah arsitektur jaringan saraf tiruan yang dirancang secara khusus untuk mengatasi keterbatasan pada RNN standar, terutama terkait masalah gradien yang menghilang pada kasus di mana urutan data terlalu panjang (*vanishing gradient problem*) [18]. Berbeda dengan RNN konvensional yang sulit mempertahankan informasi dalam jangka waktu lama, LSTM memiliki struktur internal yang lebih kompleks sehingga memungkinkannya untuk mempelajari ketergantungan jangka panjang (*long-term dependencies*) pada data sekuensial secara lebih efektif [18].

Komponen inti yang membedakan LSTM dari RNN adalah keberadaan *cell state* dan mekanisme gerbang (*gates*) yang mengatur aliran informasi [18]. *Cell state* bertindak sebagai jalur informasi pusat yang melintasi seluruh urutan data dengan perubahan yang minimal, sehingga informasi penting dapat dipertahankan di banyak langkah waktu [18]. Untuk memodifikasi atau memperbarui informasi pada *cell state* tersebut, LSTM menggunakan tiga jenis gerbang utama [18]:

- a. **Gerbang Lupa (*Forget Gate*)**: Berfungsi untuk menentukan informasi mana dari *cell state* sebelumnya yang tidak lagi relevan dan harus dibuang [18].
- b. **Gerbang Input (*Input Gate*)**: Berfungsi untuk memutuskan informasi baru mana yang akan disimpan ke dalam *cell state* [18].
- c. **Gerbang Output (*Output Gate*)**: Berfungsi untuk menentukan bagian mana dari *cell state* yang akan dikeluarkan sebagai *output* atau diteruskan ke langkah waktu berikutnya sebagai *hidden state* [18].

Melalui mekanisme pengaturan gerbang tersebut, LSTM mampu melakukan operasi penambahan atau penghapusan informasi secara selektif [18]. Hal ini menjadikan LSTM sangat kuat dalam menangani data yang memiliki jeda waktu lama antar peristiwa penting, seperti pada penelitian ini yang memerlukan pengenalan gestur tangan dinamis yang membutuhkan pemahaman terhadap urutan gerakan dari awal hingga akhir [18].

2.2.6 Tensorflow dan Tensorflow Lite

TensorFlow merupakan sebuah kerangka kerja (*framework*) *machine learning* dengan sumber terbuka (*open-source*) dari hulu-ke-hilir (*end-to-end*) yang dikembangkan oleh Google [19]. Kerangka kerja ini memfasilitasi pembangunan, pelatihan, dan penerapan model *deep learning* serta algoritma *machine learning* lainnya melalui ekosistem atau *environment* alat yang sangat komprehensif [19]. Dalam lingkungan pengembangannya, TensorFlow mendukung berbagai antarmuka pemrograman, di mana Python menjadi bahasa utama yang paling sering digunakan karena fleksibilitasnya dalam menangani komputasi matematis yang kompleks serta aksesibilitasnya yang tinggi bagi para peneliti dan pengembang [19].

Sementara itu, TensorFlow Lite (TFLite) merupakan versi ringan dari ekosistem TensorFlow yang dirancang secara spesifik untuk tahap inferensi pada perangkat *mobile*, perangkat tertanam (*embedded devices*), dan *Internet of Things* (IoT) [27]. Perangkat komputasi yang terletak di tepi jaringan (*Edge AI* atau *TinyML*) sering kali memiliki keterbatasan terkait kapasitas memori, daya komputasi prosesor, dan batas konsumsi energi [27]. TensorFlow Lite menyelesaikan permasalahan tersebut dengan mengonversi model *machine learning* yang telah dilatih di lingkungan komputasi tinggi (seperti model klasifikasi gestur dengan format TensorFlow standar) menjadi format model yang sangat ringkas dan ringan sehingga dapat dieksekusi oleh mikrokontroler atau komputer papan tunggal (*Single Board Computer*) [27].

Pada penelitian ini, TensorFlow dan TensorFlow Lite berperan penting dalam merealisasikan *Touchless Interface Vending Machine*. TensorFlow diperlukan untuk merancang arsitektur dan melatih model LSTM serta untuk melakukan evaluasi awal untuk memastikan bahwa model dapat menerjemahkan gestur tangan. Sementara itu, TensorFlow Lite berfungsi untuk mengubah model TensorFlow ke bentuk yang lebih ringan agar dapat digunakan dengan lebih efisien oleh perangkat *edge*, yang pada penelitian ini adalah Raspberry Pi 5.


2.2.7 Raspberry Pi 5

Raspberry Pi 5 merupakan generasi terbaru dari seri komputer papan tunggal (*Single Board Computer* atau SBC) yang dikembangkan oleh Raspberry Pi Foundation. Produk ini dirancang untuk memberikan peningkatan performa komputasi dan grafis secara signifikan dibandingkan para pendahulunya [21]. Perangkat ini ditenagai oleh *System-on-Chip* (SoC) Broadcom BCM2712 yang memiliki prosesor *quad-core* Arm Cortex-A76 64-bit dengan kecepatan *clock* 2.4 GHz, serta dilengkapi dengan GPU VideoCore VII [21]. Selain itu, Raspberry Pi 5 juga menghadirkan arsitektur memori yang lebih cepat serta pengontrol I/O (*Input/Output*) khusus (RP1) yang mempercepat transfer data sensor dan kamera, menjadikannya platform perangkat keras yang sangat tangguh dalam menangani beban komputasi yang intensif [21].

Dalam konteks penerapan kecerdasan buatan pada *Internet of Things* (IoT), spesifikasi tinggi pada Raspberry Pi 5 menjadikannya sebagai alat yang sangat ideal untuk digunakan sebagai mesin *Edge Computing* untuk menjalankan algoritma *machine learning* secara *real-time* [22]. Komputasi tepi (*Edge AI*) memungkinkan data diproses secara langsung pada perangkat lokal tanpa harus bergantung pada pengiriman data ke *cloud server* [22]. Pendekatan ini menawarkan keuntungan teknis yang penting, antara lain minimnya latensi akibat keterlambatan transmisi jaringan, penghematan *bandwidth*, dan privasi data pengguna yang lebih aman [22]. Dengan mengintegrasikan kerangka kerja seperti TensorFlow dan TensorFlow Lite, kemampuan prosesor Raspberry Pi 5 terbukti mampu mengeksekusi proses inferensi untuk model *computer vision* secara efisien dan mandiri (*offline*) pada lingkungan nyata di lapangan [22].

Oleh karena kemampuannya, Raspberry Pi 5 dipilih sebagai mesin *Edge Computing* untuk penelitian ini. Raspberry Pi 5 akan menjalankan hampir seluruh alur kerja yang ada pada sistem *vending machine*, mulai dari pengambilan input video dari *web camera*, penerjemahan perintah

dari input video dengan menggunakan model LSTM, hingga mengeksekusi perintah tersebut pada *software* maupun *hardware vending machine*.



Gambar 2.3: Raspberry Pi 5

BAB 3 METODOLOGI

3.1 Metode yang Digunakan

Penelitian ini menggunakan metode eksperimental. Pendekatan eksperimental ini dipilih untuk merancang, mengevaluasi, dan mengoptimalkan performa model klasifikasi gestur tangan dinamis pada sistem *vending machine*. Secara spesifik, penelitian akan melakukan serangkaian pengujian sistem pada simulasi lingkungan publik yang dinamis, di mana variabel eksternal seperti tingkat pencahayaan (terang dan redup) serta kompleksitas latar belakang visual (*background*) akan divariasikan. Kinerja sistem kemudian akan diukur secara kuantitatif berdasarkan tingkat akurasi pengenalan gestur dan latensi waktu inferensi untuk memastikan sistem dapat berjalan secara *real-time*.

3.2 Bahan dan Peralatan yang Digunakan

Untuk merealisasikan sistem *touchless interface* yang diusulkan, dibutuhkan komponen perangkat keras (*hardware*) dan perangkat lunak (*software*) sebagai berikut:

3.2.1 Hardware

- a. **Komputer Pengembangan:** Laptop Acer Nitro 5 yang dialokasikan khusus untuk melakukan proses pelatihan dan pengembangan arsitektur model LSTM secara intensif.
- b. **Perangkat Edge Computing:** Single Board Computer Raspberry Pi 5 sebagai pusat komputasi lokal untuk menjalankan inferensi model secara mandiri dan *real-time*.
- c. **Perangkat Input:** Webcam dengan resolusi HD 1080p untuk menangkap *frame* video interaksi gestur tangan pengguna dengan jelas.
- d. **Perangkat Output (Aktuator):** Mikrokontroler ESP32-S3 yang difungsikan sebagai aktuator eksternal untuk menerima sinyal dan mengeksekusi simulasi perintah mekanik pada *vending machine*.
- e. **Komponen Pendukung:** Power Supply 5 V 5 A untuk menyuplai daya secara stabil kepada Raspberry Pi 5 selama sistem beroperasi.


3.2.2 Software

- a. **Sistem Operasi:** Raspberry Pi OS untuk perangkat *edge*.
- b. **Bahasa Pemrograman:** Python (versi 3.11.8).
- c. **Pustaka dan Kerangka Kerja (Framework):**
 - i. **OpenCV:** Untuk mengakses *webcam* dan melakukan pemrosesan input video dasar.
 - ii. **MediaPipe:** Untuk mendeteksi keberadaan tangan dan mengekstrak 21 titik koordinat spasial (*landmarks*) secara *real-time*.
 - iii. **TensorFlow & Keras:** Untuk merancang arsitektur, melatih, serta mengevaluasi model jaringan saraf LSTM.
 - iv. **TensorFlow Lite:** Untuk mengonversi dan mengoptimasi model LSTM agar ringan dan efisien saat dieksekusi oleh Raspberry Pi 5.
 - v. **NumPy:** Untuk manipulasi dan perhitungan data matriks (seperti koordinat *landmark*).

- vi. **Scikit-learn**: Untuk membagi *dataset* serta mengevaluasi performa model.
- vii. **RPi.GPIO**: Untuk antarmuka kontrol pin GPIO pada Raspberry Pi dalam berkomunikasi dengan perangkat aktuator.

3.3 Urutan Pelaksanaan Penelitian

Pelaksanaan penelitian ini dibagi menjadi beberapa tahapan utama yang saling berurutan, mulai dari pengambilan data hingga pengujian sistem akhir. Alur kerja penelitian diilustrasikan pada Gambar 3.1 dan dijelaskan secara rinci pada setiap tahapannya.



Gambar 3.1: Diagram Blok Alur Penelitian

3.3.1 Pengambilan Dataset

Tahap awal adalah membangun *dataset* gestur tangan dinamis. Proses ini dilakukan dengan merekam video dari serangkaian gerakan intuitif dasar yang diperlukan untuk mengoperasikan *vending machine*, seperti gestur navigasi layar (atas, bawah, kiri, kanan) dan gestur konfirmasi pemilihan produk. Perekaman ini akan diotomatisasi melalui skrip Python menggunakan **OpenCV**.

3.3.2 Ekstraksi Fitur & Preprocessing

Data video mentah kemudian diproses agar dapat dipahami oleh jaringan saraf. Skrip Python akan memanfaatkan **MediaPipe** untuk menganalisis setiap *frame* video dan mengekstrak 21 *landmark* koordinat 3D (x, y, z) dari tangan yang terdeteksi. Urutan matriks titik koordinat spasial ini kemudian dinormalisasi menjadi data sekuensial temporal untuk dimasukkan ke dalam model.

3.3.3 Pelatihan & Pengembangan LSTM

Tahap ini dilakukan sepenuhnya pada komputer pengembangan (Acer Nitro 5). Arsitektur model *Long Short-Term Memory* (LSTM) akan dibangun menggunakan **TensorFlow/Keras**. *Dataset* koordinat yang sudah diekstraksi akan dilatih agar model mampu mempelajari pola ketergantungan jarak jauh (*long-term dependencies*) dari setiap urutan gerakan dinamis untuk mengklasifikasikan gestur.

3.3.4 Pengujian & Optimisasi LSTM

Setelah divalidasi fungsionalitasnya di komputer, model LSTM akan dioptimasi secara struktural menggunakan **TensorFlow Lite**. Format model standar akan dikonversi menjadi format **.tflite** untuk memperkecil ukuran parameter dan mempercepat waktu inferensi, sehingga memenuhi batasan sumber daya memori dan komputasi pada perangkat *edge*.

3.3.5 Instalasi OS Raspberry Pi 5

Menyiapkan *environment* pada perangkat keras utama dengan melakukan instalasi **Raspberry Pi OS**, konfigurasi antarmuka I/O, serta pemasangan seluruh dependensi perangkat lunak yang dibutuhkan, seperti **Python 3.11.8**, **OpenCV**, **MediaPipe**, dan *interpreter TFLite*.

3.3.6 Integrasi Model & OS di Raspberry Pi 5

Memindahkan model `.tflite` yang telah dioptimalkan ke dalam penyimpanan lokal Raspberry Pi 5. Pada tahap ini, koneksi perangkat keras fisik juga dirangkai, yaitu menghubungkan *webcam* HD 1080p melalui USB dan menyambungkan pin GPIO ke mikrokontroler **ESP32-S3**.

3.3.7 Inferensi Real-Time & Kontrol Aktuator

Implementasi kode program utama pada Raspberry Pi 5 yang akan berjalan terus-menerus. Sistem akan membaca *frame* kamera, mengekstraksi *landmark* dengan **MediaPipe**, menampung urutannya ke dalam *buffer*, dan melakukan inferensi menggunakan **TensorFlow Lite** secara *real-time*. Hasil prediksi tersebut kemudian diterjemahkan menjadi sinyal perintah dan dikirim ke mikrokontroler **ESP32-S3** untuk mengaktifkan fungsi tertentu (mensimulasikan sistem internal *vending machine*).

3.3.8 Evaluasi

Sistem diuji secara menyeluruh dengan skenario yang mensimulasikan lingkungan ruang publik yang dinamis. Evaluasi ini memfokuskan pengukuran pada aspek metrik keandalan, seperti persentase akurasi model dalam mengenali gestur pengguna yang berbeda, serta pengujian ketahanan kecepatan inferensi (*latency*) pada fluktuasi pencahayaan dan latar belakang yang heterogen.

3.3.9 Jadwal Pelaksanaan Penelitian

Tabel 3.1: Tabel timeline

Kegiatan	Minggu															
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Pengambilan data dan pengembangan model																
Desain prototype vending machine																
Integrasi model pada prototype																
Evaluasi dan optimisasi sistem																
Penulisan Laporan Akhir																

Pada *timeline* yang tertera di Tabel 3.1, jadwal pelaksanaan penelitian dirancang agar dapat diselesaikan secara sistematis dalam kurun waktu 16 minggu. Tahap pertama difokuskan pada pengambilan data dan pengembangan model deteksi gestur menggunakan arsitektur LSTM, yang dialokasikan pada empat minggu pertama. Tahap kedua adalah perancangan dan desain *prototype vending machine* yang berlangsung mulai dari minggu ke-5 hingga minggu ke-8. Setelah prototipe fisik siap, penelitian memasuki tahap integrasi antara model deteksi gestur yang telah dilatih ke dalam *prototype* tersebut pada minggu ke-9 dan ke-10. Tahap terakhir merupakan fase krusial yaitu evaluasi dan perbaikan sistem yang dilakukan secara komprehensif mulai dari minggu ke-11 hingga akhir jadwal penelitian (minggu ke-16). Evaluasi ini bertujuan untuk memastikan sistem *touchless interface* dapat beroperasi secara akurat, responsif, dan *real-time* pada kondisi lingkungan *vending machine* publik.


[Halaman ini sengaja dikosongkan]

BAB 4 HASIL SEMENTARA

4.1 Software

4.1.1 Akuisisi Dataset dan Pelatihan


Pada tahap ini, dilakukan proses akuisisi dataset dengan merekam sekuens gerakan tangan yang kemudian diekstraksi menjadi data *landmark*. Data ini digunakan untuk proses pelatihan model LSTM guna mengenali pola gestur dalam satu runtun waktu.




Gambar 4.1: Proses akuisisi dataset dan pelatihan model

4.1.2 Uji Coba Model dan *Debugging*

Setelah model dilatih, tahapan selanjutnya adalah melakukan uji coba serta *debugging*. Proses *debugging* difokuskan pada penelusuran berbagai kasus di mana suatu sekuens gerakan menghasilkan klasifikasi yang tidak diharapkan, sehingga penyebab kegagalan klasifikasi dapat diidentifikasi dan diperbaiki.



Gambar 4.2: Uji coba model - Kelas Unknown



Gambar 4.3: Uji coba model - Kelas OK

4.2 Hardware

4.2.1 Setup Raspberry Pi dan Web Cam

Pada bagian *hardware*, telah dilakukan *setup* Raspberry Pi beserta *web cam* yang sudah siap untuk digunakan. Perangkat ini dipersiapkan sebagai sistem komputasi utama untuk mem-


proses deteksi gestur secara *real-time* pada *vending machine*.



Gambar 4.4: Setup Raspberry Pi dan Web Cam

4.2.2 Uji Coba Rangkaian

Sebelum diimplementasikan menggunakan rangkaian fisik secara penuh pada *vending machine*, dilakukan uji coba rangkaian untuk memastikan fungsionalitas dan logika perakitan komponen dapat bekerja dengan benar.



Gambar 4.5: Uji coba rangkaian sebelum menggunakan komponen fisik

4.3 Kesimpulan Sementara

Berdasarkan progres pengembangan yang telah dilakukan, dapat ditarik beberapa kesimpulan sementara sebagai berikut:

1. Model saat ini masih memerlukan pengembangan, terutama penentuan parameter agar hasil deteksi menjadi lebih *robust*.
2. Desain *hardware* masih disesuaikan dengan kondisi nyata di lapangan (ketersediaan komponen, memastikan apakah komponen dapat bekerja dengan sebagaimana mestinya, dan sebagainya).
3. Raspberry Pi sudah siap dipakai untuk melakukan pengambilan dataset serta uji coba model, walaupun untuk saat ini proses tersebut masih dikerjakan menggunakan laptop.

[Halaman ini sengaja dikosongkan]

DAFTAR PUSTAKA

- [1] U. Rozman, M. Lorber, A. Bolha, J. B. Bahar, M. Lavrič, and Š. Š. Turk, “Sustainability aspects of food and drinks offered in vending machines at slovenian universities,” *Frontiers in Nutrition*, vol. 12, p. 1 439 690, 2025.
- [2] K. S. Rajesh, K. Sudha, S. Kalaiselvi, and G. Kavitha, “Smart vending machines: Improving service quality with integrated controllers and svm algorithm,” in *2024 6th International Conference on Energy, Power and Environment (ICEPE)*, IEEE, 2024.
- [3] M. Yang, Z. Dou, W. Liu, X. Li, and N. Zhang, “Real touch behaviors and control strategies of norovirus transmission among young children in kindergarten: An on-site investigation and intervention study,” *Building and Environment*, vol. 286, p. 113 690, 2025.
- [4] S. Xiao, C. Li, F. Zhao, R. Lin, N. Zhang, and Y. Li, “A coupled hand and surface hygiene criterion on heterogeneous surface touch networks,” *Journal of Hazardous Materials*, vol. 479, p. 135 589, 2024.
- [5] P. Grobelny and A. Narbudowicz, “Mm-wave radar-based recognition of multiple hand gestures using long short-term memory (lstm) neural network,” *Electronics*, vol. 11, no. 5, p. 787, 2022.
- [6] J. Kotti, B. Padmaja, and D. Deepa, *Enhancing gesture-controlled virtual mouse and virtual keyboard using ai techniques*, 2024.
- [7] G. Batnasan, M.-E. Otgonbold, Q. A. Memon, T. K. Shih, and M. Gochoo, “Head and hands tunneling pipeline for enhancing sign language recognition,” *IEEE Access*, vol. 13, p. 127 940, 2025.
- [8] M. Geetha, N. Aloysius, D. A. Somasundaran, A. Raghunath, and P. Nedungadi, “Toward real-time recognition of continuous indian sign language: A multi-modal approach using rgb and pose,” *IEEE Access*, vol. 13, p. 60 283, 2025.
- [9] G. H. Samaan *et al.*, “Mediapipe’s landmarks with rnn for dynamic sign language recognition,” *Electronics*, vol. 11, no. 19, p. 3228, 2022.
- [10] A. Toro-Ossaba, J. Jaramillo-Tigrreros, J. C. Tejada, A. Peña, A. López-González, and R. A. Castanho, “Lstm recurrent neural network for hand gesture recognition using emg signals,” *Applied Sciences*, vol. 12, no. 19, p. 9700, 2022.
- [11] H. M. A. Ghanimi, S. Sengan, V. B. Sadu, *et al.*, “An open-source mp + cnn + bilstm model-based hybrid model for recognizing sign language on smartphones,” *International Journal of System Assurance Engineering and Management*, vol. 15, pp. 3794–3806, 2024.
- [12] W. Qi, S. E. Ovrur, Z. Li, A. Marzullo, and R. Song, “Multi-sensor guided hand gesture recognition for a teleoperated robot using a recurrent neural network,” *IEEE Robotics and Automation Letters*, vol. 6, no. 3, pp. 6039–6046, 2021.
- [13] G. Li, D. Li, and A. Yang, “Real-time hand gesture detection based on yolov5s,” in *Proceedings of the 41st Chinese Control Conference*, Hefei, China, 2022.

- [14] A. A. Jairoun *et al.*, “Examining the evolution and impact of otc vending machines in global healthcare systems,” *Exploratory Research in Clinical and Social Pharmacy*, vol. 16, p. 100 540, 2024.
- [15] M. S. Yusof, N. Fauzi, A. Jamaludin, S. A. Seman, M. N. Salleh, and N. E. Tasrip, “Technological advancements in vending machines transforming consumer behavior market trends and the future of automated retail,” *Journal of Posthumanism*, vol. 5, no. 6, pp. 139–149, 2025.
- [16] J. Wang, “Construction and optimization of vending machine decision system based on artificial intelligence,” in *2023 IEEE International Conference on Control, Electronics and Computer Engineering (ICCECE)*, 2023.
- [17] Google AI Edge, *Hand landmarker task guide - mediapipe*, [Online; diakses 11 April 2026], 2026. [Online]. Available: https://ai.google.dev/edge/mediapipe/solutions/vision/hand_landmarker.
- [18] H. Chen, M. Zheng, and C. Li, “Db-rnn: An rnn for precipitation nowcasting deblurring,” *arXiv preprint arXiv:2407.03661*, 2024.
- [19] E. Uchegbulam and I. Ogedegbe, “Comparing tensorflow.js and tensorflow in python: An accessibility and usage analysis,” *Texas Journal of Engineering and Technology*, vol. 2, pp. 28–36, 2023.
- [20] G. B. A. Laksana, “Analisis performa tensorflow lite untuk iot dengan esp32 devkit-c,” Universitas Brawijaya, 2024.
- [21] Raspberry Pi, *Raspberry pi 5*, [Online; diakses 11 April 2025], 2025. [Online]. Available: <https://www.raspberrypi.com/products/raspberry-pi-5/>.
- [22] P. Ranjan *et al.*, “Tensorflow, computer vision, and edge ai-based face recognition attendance monitoring system using raspberry pi 5,” in *Proceedings of the 2025 13th International Conference on Intelligent Embedded, MicroElectronics, Communication and Optical Networks (IEMECON)*, Jaipur, India, 2025, pp. 1–5. doi: 10.1109/IEMECON69302.2025.11365706.